TAPE

Territorio, Actividades y Potencial Económico

Pasos siguientes para continuar el trabajo

Documento de traspaso entre Joaquín Sostoa y su socio. Actualizado el 12 de octubre de 2026. Se basa en docs/ESTADO.md, docs/PLAN_fase0_fase1.md y docs/COLABORACION.md del repositorio, que son la referencia vigente.

1. Dónde estamos

- Fase 0 (fundamentos) cerrada: estructura del repositorio, taxonomía de 67 sectores TAPE y puente HS → CPC → CIIU → sector.
- Fuentes internacionales descargables: BACI, Atlas de Complejidad, WDI (15 indicadores), PWT, LPI, concordancias de la ONU, límites administrativos, 10 tablas de SIMEL, NBER-CES y la concordancia HS → NAICS.
- Fuentes nacionales ya incorporadas: PIB por 33 actividades y regional (BCP), crédito por sector, MIP de 21 sectores, EPHC 2022–2025, censo agropecuario 2022 (por departamento y por distrito), carreras de la ANEAES, establecimientos del MEC y siete capas del mapa logístico del MIC.
- Fase 1 (módulo nacional) en marcha: hechas la tarea 1.5 (dotaciones por país) y la 1.6 (requisitos por producto). Ever subió borradores de las tareas 1.2, 1.3, 1.4, 1.7 y 1.8 en src/modelos/. Pasan 125 pruebas.
- Decisiones tomadas el 12 de octubre: D3 (proximidad con ventana de 5 años), D4 (intensidades con NBER-CES y energía con el precio de la electricidad) y D6 (reexportaciones marcadas por regla automática).

2. Puesta en marcha (una sola vez)

1. Traer los cambios del repositorio con git pull.
2. Bajar TAPE_datos_manuales.zip de la carpeta compartida de Drive (45 MB) y descomprimirlo en la raíz del repositorio, donde están data/, src/ y docs/. Deja los archivos en data/raw/<fuente>/.
3. Ejecutar, en este orden:

```
uv sync
uv run python -m src.descargas.todas      # ≈ 4 GB; si se corta, repetir
uv run python -m src.reconstruir_todo
uv run pytest
```

4. Anotar en docs/ESTADO.md, sección «Quién hace qué», la tarea que toma cada persona.

Requisitos: Python 3.12, uv y Git. Si algún comando falla, enviar el mensaje de error completo.

3. Estado de las tareas de la Fase 1

Tarea	Estado	Qué falta
1.1 Limpieza de BACI	El borrador de Ever trabaja sobre su base DuckDB	Reproducible desde el repositorio
1.2 Depuración	Borrador de Ever (energía HS 271600 y reexportaciones)	Recalcular el RCA después de depurar; aplicar la depuración a la presencia y la densidad
1.3 RCA y presencia	Borrador de Ever (presencia con promedio móvil de 3 años)	Contrastar con el RCA del Atlas; D7 sin decidir

Tarea	Estado	Qué falta
1.4 Proximidad y densidad	Borrador de Ever; versión liviana hecha (densidad_np.py)	Pasar a la versión liviana; contrastar con la distancia del Atlas
1.5 Dotaciones por país	HECHA (docs/dotaciones.md)	—
1.6 Requisitos por producto	HECHA (docs/puente_requisitos.md)	Decidir qué hacer con agro, minería y servicios (sin dato)
1.7 Panel de entradas	Borrador de Ever	D7 y D8 sin decidir; sus constantes de D8 no se aplican
1.8 Modelo de densidad sola	Borrador de Ever; versión liviana del logit hecha (logit_disperso.py)	Pasar a la versión liviana
1.9 a 1.11	Pendientes	D2 para el logit y D1 para el informe

4. Decisiones

Decididas el 12 de octubre de 2026 (detalle en docs/supuestos.md):

- **D3:** proximidad entre productos con ventana de 5 años que termina en el año de corte; la distancia del Atlas solo sirve de control.
- **D4:** intensidades por producto con NBER-CES y la tabla NAICS → HS de Pierce y Schott; energía = precio de la electricidad (Doing Business, promedio 2014-2019).
- **D6:** reexportaciones de Paraguay marcadas con una regla automática (importaciones y exportaciones del mismo orden), a revisar después con la aduana.
- **Decididas antes:** D5 (HS92; 4 dígitos para estimar y 6 para el puente), D9, D11 y D12.

Siguen abiertas, de la más urgente a la menos urgente. La recomendación es la propuesta del plan:

#	Decisión	Desbloquea	Recomendación
D7	Definición de entrada sostenida	1.7	RCA con promedio móvil de 3 años, y una variante que exige RCA ≥ 1 en dos de tres años. Ever ya implementó la primera.
D8	Muestra de países	1.7	Excluir países de menos de 1 millón de habitantes o con exportaciones muy bajas, y reportar el filtro.
D2	Efectos fijos y predicción fuera de muestra	1.9	Efectos fijos constantes más dummies de ventana; Mundlak para los países excluidos.
D1	Paso de producto a sector TAPE	1.11	Media de la probabilidad ponderada por exportación mundial, con máximo y conteo como respaldo.

D10 (umbral ε de las reglas de política) se deja abierto hasta la Fase 3.

5. Hallazgos que hay que resolver

- Capital humano, crédito y logística están muy correlacionadas entre sí (0,65 a 0,76); la energía (precio) es independiente. Decidir en la tarea 1.9 cómo tratarlo.
- Agricultura, minería y servicios no tienen requisitos (NBER-CES es solo manufactura): 13 % del valor mundial, incluida la soja en grano. Decidir cómo tratarlos en el modelo y en el módulo territorial.
- depurar.py quita la energía y las reexportaciones pero no recalcula el RCA: el RCA de los demás productos de Paraguay queda subestimado (la energía es el 23 % de sus exportaciones).
- El precio de la electricidad solo existe para 2014-2019: en la robustez, repetir el modelo con las ventanas desde 2015.

6. Datos pendientes (Joaquín)

Pendiente	Estado
Registro de títulos del MEC	Solicitud formal enviada el 12/10 (agregado, sin datos personales). Plazo de respuesta: 2/11.
Registro Nacional de Carreras del MEC	Descarga manual; el sitio rechaza scripts.
Censo Económico 2011 por distrito	Pedido formal al INE (la página no respondía).
Régimen de materia prima	Pedido formal al MIC.
Cuadros de oferta y utilización detallados	Pedido formal al BCP.
Cultivos y ganadería del censo agropecuario por distrito	Otro tomo del censo, si existe.
Licencias de BACI, Atlas, SIMEL y del visor del MIC; año de las aduanas; autoría de la MIP	Confirmar con las instituciones antes de publicar.

En paralelo, para la Fase 2: reconciliar los 247 distritos de los límites de 2012 con los 263 del Censo 2022 y definir carrera → CINE-F → sector cuando lleguen los títulos.

7. Rendimiento: bases DuckDB y modelos

El cálculo de la densidad en SQL generaba unos 1.600 millones de filas por ventana, y el logit con efectos fijos de statsmodels arma una matriz densa de 14 a 16 GB: el disco de Ever perdió unos 60 GB. Medido con datos reales, las versiones livianas lo evitan:

Versión liviana	Reemplaza	Resultado (ventana real)
src/modelos/densidad_np.py	la densidad en SQL	3,7 segundos y 490 MB; idéntica a la versión SQL
src/modelos/logit_disperso.py	el logit de statsmodels	37 segundos y 400 MB (en vez de unos 16 GB)

- Las bases .duckdb no se suben a Git ni a un servidor (Railway, Cloudflare): solo las tablas resultado en parquet.
- Las rutas de la base se pasan por parámetro, no fijas en el código (hoy hay rutas C:\ever\... y dos copias de la base).
- Cómo recuperar espacio en el disco: docs/optimizacion_modelos.md.

8. Reparto de tareas

- **Ever:** pasa sus módulos a densidad_np.py y logit_disperso.py, recalcula el RCA después de depurar, aplica la depuración a la presencia y la densidad, saca las rutas fijas y sube los cambios con pruebas.
- **Joaquín:** decide D7 y D8 con Ever, consigue los datos pendientes de la sección 6.
- **Claude Code:** hechas la 1.5, la 1.6 y las versiones livianas. Siguiente: revisar los módulos de Ever contra D3, D5 y D6 cuando los suba.
- **Reglas de trabajo:** una tarea por rama (por ejemplo fase1/1-1-limpieza-baci), pruebas y lint en verde antes de cada commit, pull request revisado por la otra persona, no editar nunca data/raw/ y los archivos existentes de src/modelos/ los modifica solo quien trabaja ese módulo.

9. Avisos

- El repositorio de GitHub está público de forma temporal para que lo lea la IA del socio. Se vuelve a poner privado cuando termine. No subir nada sensible mientras tanto.
- Los datos del visor del MIC vienen de una página pública sin licencia declarada: son provisorios y de uso interno hasta tener la entrega oficial.