

TAPE

Territorio, Actividades y Potencial Económico

Pasos siguientes para continuar el trabajo

Documento de traspaso entre Joaquín Sostoa y su socio. Fecha: 9 de octubre de 2026. Se basa en docs/PLAN_fase0_fase1.md, docs/ESTADO.md y docs/COLABORACION.md del repositorio, que son la referencia vigente.

1. Dónde estamos

- Fase 0 (fundamentos) cerrada: estructura del repositorio, taxonomía de 67 sectores TAPE y puente HS → CPC → CIIU → sector.
- Fuentes internacionales descargables: BACI, Atlas de Complejidad, WDI, PWT, LPI, concordancias de la ONU, límites administrativos y 10 tablas de SIMEL.
- Fuentes nacionales ya incorporadas: PIB por 33 actividades y regional (BCP), crédito por sector, MIP de 21 sectores, EPHC 2022–2025, censo agropecuario 2022 (por departamento y por distrito), carreras de la ANEAES, establecimientos del MEC y siete capas del mapa logístico del MIC (población y PEA por distrito, industrias, red eléctrica, rutas, polos y AFI, aduanas, salud).
- Fase 1 (módulo nacional): sin empezar. Pasan 95 pruebas automáticas.

2. Puesta en marcha (una sola vez)

1. Traer los cambios del repositorio con git pull.
2. Bajar TAPE_datos_manuales.zip de la carpeta compartida de Drive (45 MB) y descomprimirlo en la raíz del repositorio, donde están data/, src/ y docs/. Deja los archivos en data/raw/<fuente>/.
3. Ejecutar, en este orden:

```
uv sync
uv run python -m src.descargas.todas      # ≈ 4 GB; si se corta, repetir
uv run python -m src.reconstruir_todo
uv run pytest
```

4. Anotar en docs/ESTADO.md, sección «Quién hace qué», la tarea que toma cada persona.

Requisitos: Python 3.12, uv y Git. Si algún comando falla, enviar el mensaje de error completo.

3. Tareas que se pueden hacer ya, sin decisiones previas

Son tareas de código con un criterio de terminado claro. Cada una cierra con un resumen, una tabla o gráfico de control y un commit.

Tarea	Qué hace	Depende de
1.1 Limpieza de BACI	Lee el zip de BACI sin extraerlo y deja data/clean/comercio_hs92.parquet con país, socio, producto, año, valor y toneladas.	Nada
1.3 RCA y presencia	Funciones puras con un ejemplo hecho a mano. Se contrasta con el RCA del Atlas (correlación esperada mayor a 0,99).	1.1
1.8 Métricas de evaluación	precision@k, AUC-PR y calibración, cada una con una prueba mínima. Es el piso contra el que se compara todo.	Nada
1.5 Dotaciones (parte)	Capital humano, crédito y logística por país y año, desde WDI, PWT y LPI. La energía espera D4.	Nada

4. Decisiones que hay que tomar entre los dos

De la más urgente a la menos urgente. La recomendación es la propuesta del plan; cada decisión se anota en docs/supuestos.md con fecha y alternativa descartada.

#	Decisión	Desbloquea	Recomendación
D4	Fuente de las intensidades por producto (energía, capital, habilidades) y del costo de energía	1.5 y 1.6	Intensidades con NBER-CES; energía con un proxy de WDI al inicio. Es la capa más débil con datos públicos.
D6	Cómo marcar las reexportaciones de Paraguay	1.2	Marcar productos con importaciones y exportaciones del mismo orden y confirmar luego con la aduana.
D3	Cómo calcular la proximidad entre productos sin fuga de información	1.4	Ventana de 5 años que termina en el año de corte.
D7	Definición de entrada sostenida	1.7	RCA con promedio móvil de 3 años, y una variante que exige $RCA \geq 1$ en dos de tres años.
D8	Muestra de países	1.7	Excluir países de menos de 1 millón de habitantes o con exportaciones muy bajas, y reportar el filtro.
D2	Efectos fijos y predicción fuera de muestra	1.9	Efectos fijos constantes más dummies de ventana; Mundlak para los países excluidos.
D1	Paso de producto a sector TAPE	1.11	Media de la probabilidad ponderada por exportación mundial, con máximo y conteo como respaldo.

D10 (umbral ϵ de las reglas de política) se deja abierto hasta tener los resultados de la Fase 3.

Ya decididas: D5 (HS92; 4 dígitos para estimar y 6 para el puente), D9 (sectores a partir de CIU Rev.4), D11 (las carreras del MEC se vinculan a CIU y no a HS) y D12 (unidad común: división CIU de 2 dígitos).

5. Camino completo de la Fase 1

Tarea	Qué produce	Decisiones
1.1	Limpieza de BACI	—
1.2	Depuración: excluir la energía de Itaipú y Yacyretá (HS 271600) y marcar las reexportaciones	D6
1.3	RCA y matriz de presencia	—
1.4	Proximidad y densidad sin fuga de información	D3
1.5 y 1.6	Dotaciones por país y requisitos por producto	D4
1.7	Panel de entradas (ventanas 2000→2005→2010→2015→2020, $h = 5$ y 10)	D7, D8
1.8	Modelo de referencia: solo densidad	—
1.9	Logit con capas y efectos fijos	D2
1.10	XGBoost de control con SHAP	—
1.11	Backtest y validación; informe de la Fase 1	D1

Condición para pasar a la Fase 2: el modelo con capas supera a la densidad sola en precision@k. Los resultados se leen como asociación, no como causalidad, y siempre con su incertidumbre.

6. En paralelo: datos de la Fase 2 (territorial)

- Registro de títulos y Registro Nacional de Carreras del MEC: los consigue Joaquín. Después hay que definir carrera → CINE-F → sector. El registro de títulos trae nombres y documentos de personas: se trabaja solo con agregados y no se sube a ningún lado.

- Reconciliar los 247 distritos de los límites de 2012 con los 263 del Censo 2022. Hoy las industrias, subestaciones y rutas usan los límites viejos, y la población y el censo agropecuario usan los nuevos.
- Serie histórica de crédito más larga y datos de crédito por actividad, si se consiguen.
- Informes de maquila y de la Ley de Inversiones: última capa, como complemento y no como serie.

7. Pendientes de datos (Joaquín)

Pendiente	Cómo se consigue
Registro de títulos y de carreras del MEC	Descarga manual desde el portal del MEC (rechaza scripts).
Censo Económico 2011 por distrito	Pedido formal al INE (la página no respondía).
Régimen de materia prima	Pedido formal al MIC.
Cuadros de oferta y utilización detallados	Pedido formal al BCP.
Cultivos y ganadería del censo agropecuario por distrito	Otro tomo del censo, si existe.
Año de las cifras de aduanas y autoría de la MIP	Confirmar con el MIC y con el BCP.
Licencias de SIMEL y del visor del MIC	Confirmar con las instituciones antes de publicar.

8. Reparto sugerido

- **Tu socio:** tareas 1.1, 1.3 y 1.8. Son código puro, no esperan decisiones y desbloquean todo lo demás.
- **Joaquín con Claude Code:** decisiones D4, D6 y D3, que son las que más truncan al resto; después, los datos pendientes de la sección 7.
- **Reglas de trabajo:** una tarea por rama (por ejemplo fase1/1-1-limpieza-baci), pruebas y lint en verde antes de cada commit, pull request revisado por la otra persona, y no editar nunca data/raw/.

9. Avisos

- El repositorio de GitHub está público de forma temporal para que lo lea la IA del socio. Se vuelve a poner privado cuando termine. No subir nada sensible mientras tanto.
- Los datos del visor del MIC vienen de una página pública sin licencia declarada: son provisorios y de uso interno hasta tener la entrega oficial.